
# PySpark


Tour d'horizon : qu'est-ce que Spark et qu'apporte-t-il par rapport

aux jobs MapReduce?


# Spark est un framework de calcul distribué



# Fonctionnalités similaires à un map reduce



# Mais utilisation particulière de la RAM des workers



- Caching
- Temps réel (vs Batch processing)

### En résumé



# Spark vs — Hadoop MapReduce

**Factors** 

Speed

Written In

**Data Processing** 

Ease of Use

Caching

### Spark

100x times than MapReduce

Scala

Batch / real-time / iterative / interactive /graph

Compact & easier than Hadoop

Caches the data in-memory & enhances the system performance

### Hadoop MapReduce

Faster than traditional system


Java

Batch processing

Complex & lengthy

Doesn't support caching of data

# Intégration dans l'écosystème



# Anatomie d'une application Spark

NB: (« application » | Spark) = (« job » | MapReduce)

Une application Spark commence toujours par l'instanciation d'un « spark context »


from pyspark import SparkContext

sc = SparkContext("local", "First App")

(indique au driver l'existence d'une application pour qu'il lui alloue des workers)


# Mais que sont ces RDD (Résilent distributed datasets)?

En un mot, des collections distribuées sur la ram des workers



# Nous rencontrerons d'autres structures de données propres à Spark

History of Spark APIs



Distribute collection of JVM objects

Functional Operators (map, filter, etc.)

Distribute collection of Row objects

Expression-based operations and UDFs

Logical plans and optimizer

Fast/efficient internal representations

Internally rows, externally JVM objects

Almost the "Best of both worlds": type safe + fast

But slower than DF Not as good for interactive analysis, especially Python



Mise en place de l'environnement

## Environnement technique

Hortonworks sandbox (virtualbox)

https://fr.hortonworks.com/tutorial/hortonworks-sandbox-guide/

# Ajout du nom d'hôte

Ajouter la ligne suivante :

127.0.0.1 sandbox-hdp.hortonworks.com sandbox-hdf.hortonworks.com

- Sous linux/MacOSX dans /etc/hosts
- Sous Windows C:\Windows\System32\Drivers\etc


# Démarrage des services

Étape 1 se rendre sur **Ambari** (port 8080)

Les credentials sont

User : raj\_ops

• Mdp:raj\_ops




# Démarrage des services


Assurez-vous que les services suivants fonctionnent (le démarrage de l'ensemble de ces services est un peu long, c'est tout à fait normal)

- HDFS
- YARN
- HIVE (spark.sql va en avoir besoin)
- SPARK2
- ZEPPELIN NOTEBOOK (un genre de jupyter)

# Importation des notebooks dans Zeppelin




# Importation des données dans l'HDFS



# Troubleshooting

# Erreur Zeppelin: interpreter not found



# Les jobs ne se lancent pas => YARN

Il peut être intéressant de regarder si **trop de jobs** ne sont pas en cours sur la plateforme et les KILL au besoin

http://sandbox-hdp.hortonworks.com:8088

