SQL et BDD relationnelles : concepts, requêtes

Au programme

- **C**reate **R**ead **D**elete **U**pdate
- Bases d’administration
- Triggers
- Postgres >11.4

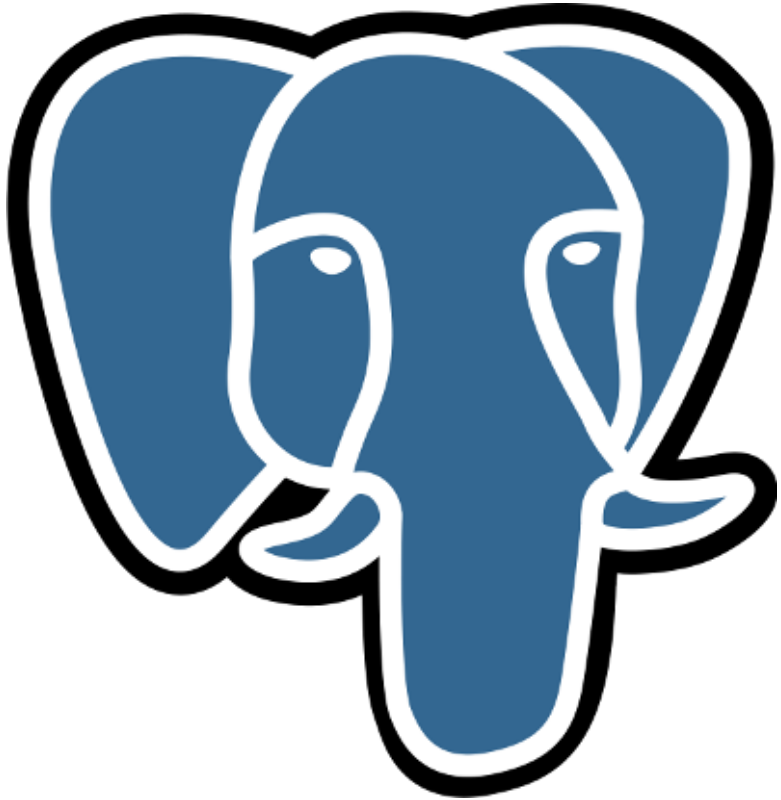

Sources et documents annexes

A des fins de reproductibilité une image docker de la base de données finale est disponible à cette adresse

Origine des données

https://www.kaggle.com/ophi/mpi

https://datahub.io/core/corruption-perceptions-index

https://data.worldbank.org/indicator/sp.pop.totl

Distinctions préliminaires

- « **SQL** » est un **langage**, non un **système de gestion de base de données** (SGBD)
- Plusieurs SGBD sont basés sur SQL. Certains sont **open source** (Postgres, MariaDB), d'autres sont **propriétaires** (MSSQL, OracleDB)
- Il existe quelques différences dans le langage de requête de ces backends, mais minimes
- La vrai différence entre ces backends concerne leur **administration** (mais nous y viendrons plus tard)

Distinctions préliminaires

SQL

ex : Postgres, OracleDB

Données structurées sous la forme de tables

No-SQL

ex : MongoDB, Cassandra

Données structurées sous la forme de graphs

Ne soyez pas naïfs ! Le fait qu'un SGDB suive une structuration par graph n'implique pas *ipso facto* qu'il soit impossible de requêter à l'aide d'un langage « *à la SQL* »

Installation de Postgres

Windows : Installer
https://www.postgresql.org/download/windows/

Linux (deb) : `apt-get install postgresql postgresql-client`

MacOSX : lol ¯_(ツ)_/¯

Création d’un utilisateur et d’une BDD

- CREATE DATABASE countries;
- CREATE USER nom_de_l’utilisateur WITH PASSWORD 'le_mdp_de_votre_choix';
- GRANT ALL PRIVILEGES ON DATABASE countries TO nom_de_l’utilisateur;

Essayez maintenant de vous logger avec ce nouvel utilisateur dans cette base :

psql -U nom_de_l’utilisateur -d countries

Création d’une table première table

```
CREATE TABLE IF NOT EXISTS mpi_national(
    iso CHAR(3) PRIMARY KEY NOT NULL,
    country_name VARCHAR(80) NOT NULL UNIQUE,
    mpi_urban REAL NOT NULL,
    headcount_ratio_urban REAL NOT NULL,
    intensity_urban REAL NOT NULL,
    mpi_rural REAL NOT NULL,
    headcount_ratio REAL NOT NULL,
    intensity_rural REAL NOT NULL
    );
```

Types et contrainte (liste non exhaustive)

Typage de données

CHAR caractères (longueur constante)

VARCHAR caractères (longueur variable)

REAL nombres (jusqu'à 6 décimales)

INTEGER entiers écrits sur 4 bytes

BIGINT entiers écrits sur 8 bytes

SERIAL entiers auto incrémentés

Contraintes d'intégrité

NULL donnée absente permise

UNIQUE occurrence unique d'une même valeur

Importation de données dans cette table

```
COPY mpi_national(iso, country_name, mpi_urban,
headcount_ratio_urban,intensity_urban,mpi_rural,headco
unt_ratio,intensity_rural)

FROM '/data/MPI_national.csv' DELIMITER ',' NULL ''
CSV HEADER ;
```

Reconnaissance

Lister les tables d’une DB :

\d

Décrire une table :

\d nom_de_ma_table

Commençons simple

Sélectionnez (dans la table : **mpi_national**)

- Le nom des pays dont le taux urbain de pauvreté (mpi_urban) est supérieur à 0,2
- Le nom des pays dont les taux urbain (mpi_urban) est supérieur à 0,1 et le taux rural (mpi_rural) est supérieur 0,6
- Le nom des pays où la pauvreté en milieu urbain est supérieure à celle du milieu rural

Commençons simple

Selection : pattern général

SELECT [colonnes] FROM [une table] WHERE [condition_que_les_lignes_doivent_remplir]

Commençons simple

Sélectionnez

- **SELECT country_name FROM mpi_national WHERE mpi_urban > 0.2;**
- **SELECT country_name FROM mpi_national WHERE (mpi_rural > 0.6 AND mpi_urban > 0.1);**
- **SELECT country_name FROM mpi_national WHERE mpi_urban < mpi_rural;**

Création d’une nouvelle table : à vous

Vous allez créer une seconde table (**mpi_subnational**) à partir du CSV du même nom.

Seule variante par rapport à table précédente : le champ iso reposera sur une **clef étrangère**

```
iso CHAR(3) REFERENCES mpi_national(iso),
```

Clefs et clefs étrangères

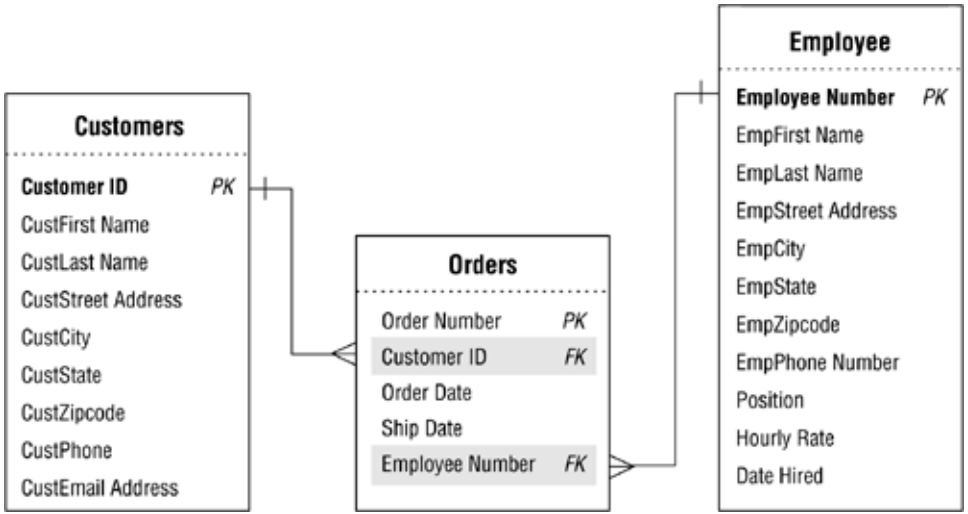

- Raison pour laquelle on parle de « **base relationnelles** »

  Mécanisme garant de :
- l'**intégrité** d'une base
- Sa **consistante**

  (importante structuration métier)

Jointures

De par la relation entre nos deux tables, nous pourrions avoir besoin d’extraire des lignes du l’une **compte tenu des données dans l’autre**

Quelques JOIN

reminder

Sélectionnez (**mpi_national** et **mpi_subnational**)

- les régions (**subregion_name**) des pays dont le ratio urbain (**headcount_ratio_urban**) est supérieur à 70
- La moyenne du taux de pauvreté urbain des pays d’asie (**world_region_name**)

Rappel sur les joins, ou de l'art de «penser avec des patates »

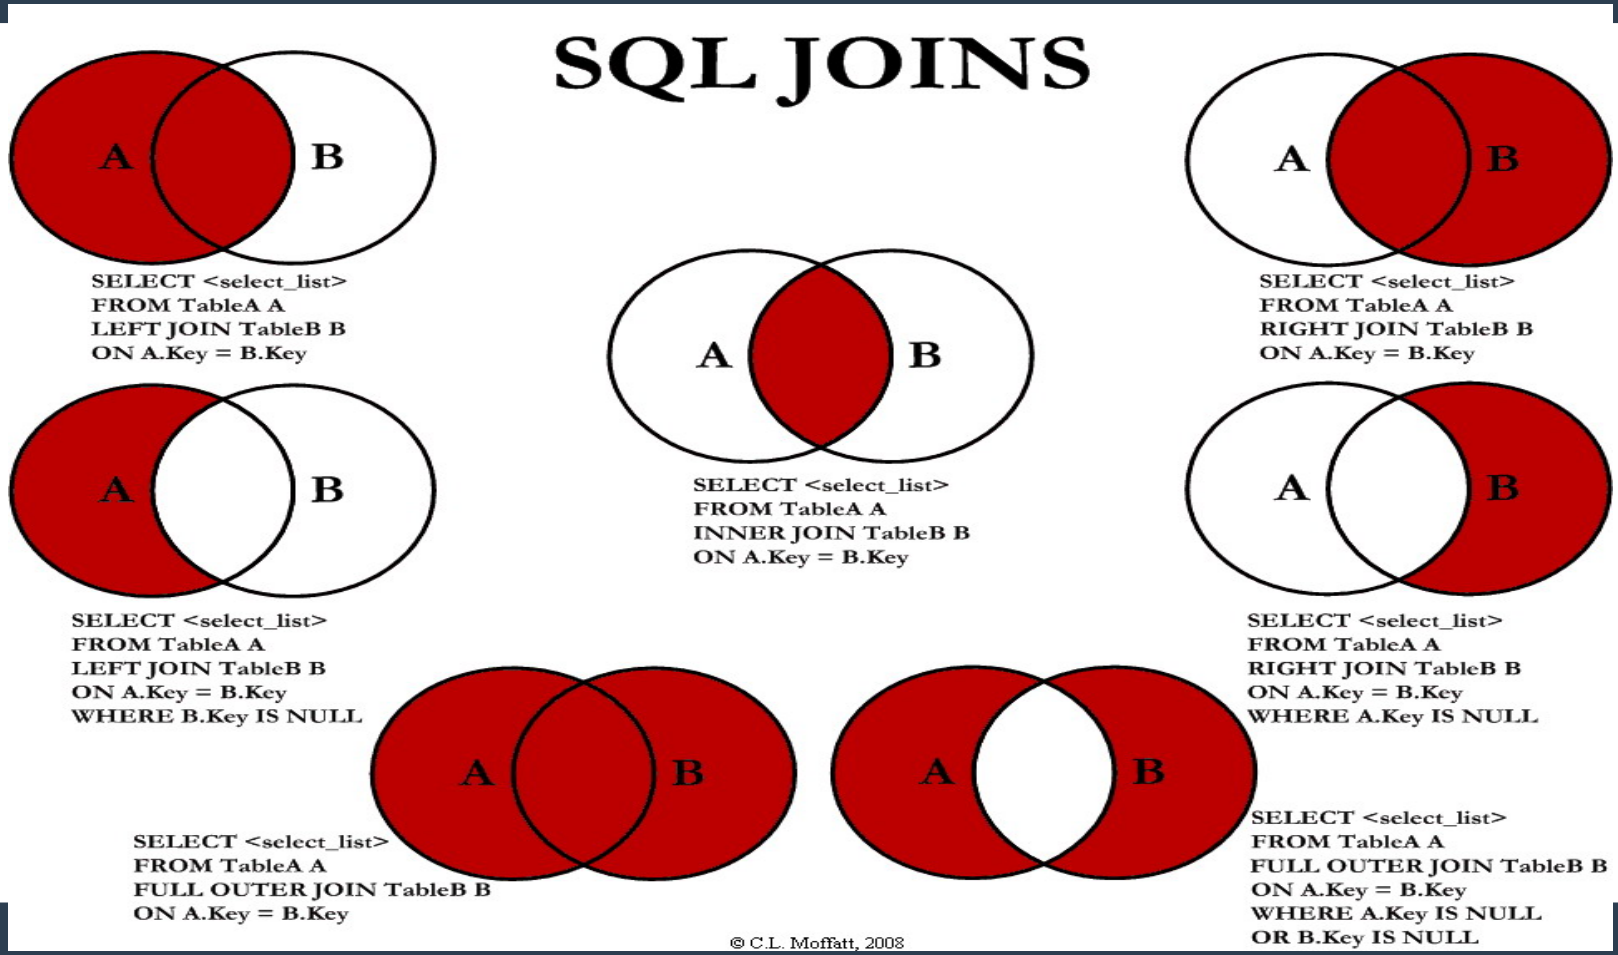

Quelques JOIN

Sélectionnez (mpi_national et mpi_subnational)

- **SELECT** mpi_subnational.region **FROM** mpi_subnational

  INNER JOIN mpi_national **ON** mpi_subnational.iso = mpi_national.iso

  WHERE mpi_national.headcount_ratio_regional >70;

Quelques JOIN

Sélectionnez (mpi_national et mpi_subnational)

- **SELECT** AVG(mpi_national.mpi_urban) **FROM** mpi_national

  INNER JOIN mpi_subnational **ON** mpi_subnational.iso = mpi_national.iso

  WHERE mpi_subnational.world_region_name="**East Asia and the Pacific**";

Quelques JOIN

Sélectionnez (MPI_national et MPI_subnational)

- **Les régions d’Asie i) dont le MPI_regional est supérieur au MPI_national et ii) dont le pays a un Headcount_Ratio_Rural supérieur à 70**
- **…. les classer par iso** en indiquant sur chaque ligne le nom du pays correspondant

Quelques JOIN

Sélectionnez (mpi_national et mpi_subnational)

```
SELECT mpi_subnational.region, mpi_subnational.country
FROM mpi_subnational INNER JOIN mpi_national ON
MPI_national.country_code = mpi_subnational.country_code
WHERE (mpi_subnational.mpi_regional >
mpi_subnational.mpi_national AND
mpi_national.headcount_ratio > 70)
ORDER BY mpi_subnational.country_code;
```

Deux nouvelles tables à créer et on est bon

Nous allons ajouter des données temporelles à notre DB

Importez les données contenues dans :

- corruption.zip
- population.zip

L’importation va probablement nécessiter quelques tweaks :/

Pivot d’une table en Postgres

Ces données temporelles mériteraient probablement d’être « pivotées ».

postgresql > 9.4 dispose d’une fonction **crosstab**() pour cela

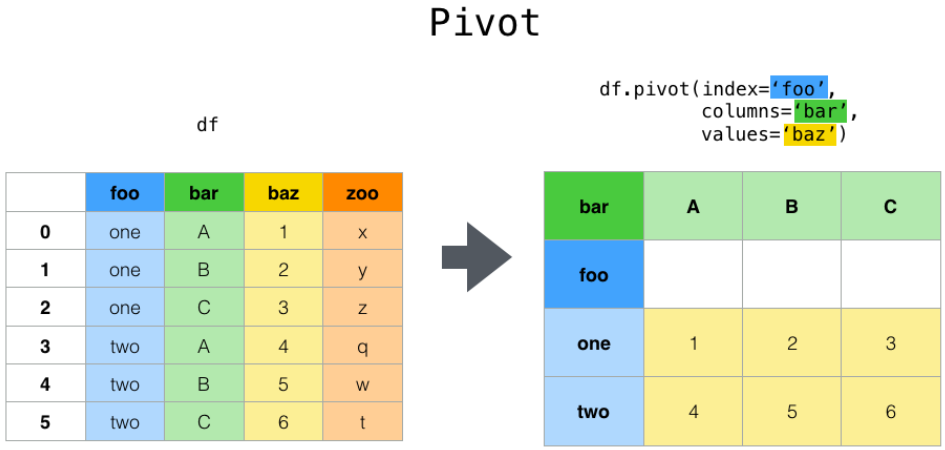

	foo	bar	baz	zoo
0	one	A	1	x
1	one	B	2	y
2	one	C	3	z
3	two	A	4	q
4	two	B	5	w
5	two	C	6	t

bar	A	B	C
foo			
one	1	2	3
two	4	5	6

Un exemple proche

Regardons du côté de la corruption et de la population

Sur population

- Quel pays possède le plus d'habitants en 2017?
- Quel pays a connu la plus faible progression de sa population depuis 1990 ?
- ‘’’’’ les trois pays
- Quel pays a connu la plus forte progression de sa population entre son premier sondage et 2010 (attention, varie d'un pays à l'autre)?

Regardons du côté de la corruption et de la population

Sur population

- **SELECT** country_name **FROM** world_population **WHERE** ‘’2017’’ = (**SELECT** MAX(‘’2017’’) **FROM** population);
- **SELECT** country_name **FROM** world_population **WHERE** (‘’2010’’ / ‘’1990’’) = (**SELECT MIN**(‘’2010’’ / ‘’1990’’) **FROM** world_population);

Chaud chaud, cacao (pour ceux qui veulent suer un coup)

- En moyenne, les pays à la pauvreté urbaine la plus importante sont-ils également ceux dont la population a connu la plus grande croissance entre les années 50 et aujourd’hui ?

Chaud chaud, cacao (pour ceux qui veulent suer un coup)

- En moyenne, les pays à la pauvreté urbaine la plus importante sont-ils également ceux dont la population a connu la plus grande croissance entre les années 50 et aujourd’hui ?

Création d’une vue

Une vue est une version épurée d’une table (ou plus vraisemblablement d’une grosse jointure) destinée être visualisée facilement par le métier sans avoir à écrire cette même requête

CREATE VIEW nom_de_votre_vue AS SELECT…….. CE QUE VOUS VOULEZ

Vue Matérialisée ? Kesako ?

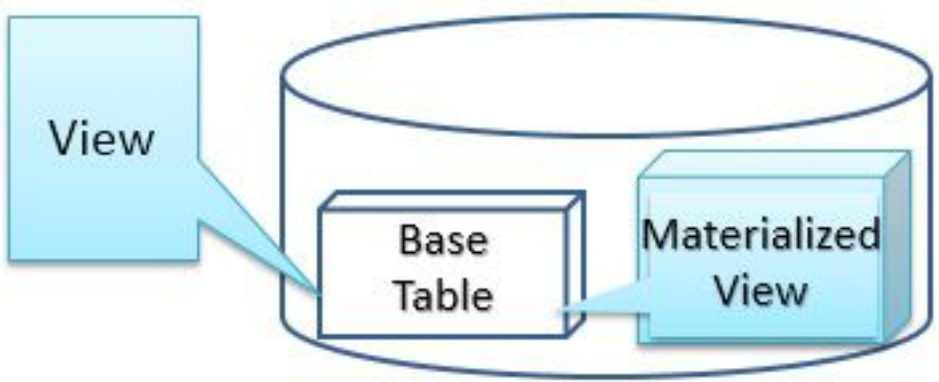

Au lieu d'être le raccourci d'une requête,

- les données sont physiquement stokées sur le disque
- Réponse plus rapide (la requête n'est pas exécutée chaque fois)
- Nécessite d'être actualisé par un trigger

Créons une vue complexe

Créez une vue du nom de european_view qui contiendra :

- l'**iso**
- Le **nom** du pays
- Le **mpi national**
- Le **taux de croissance** de population entre 1971 et 2000
- Le taux de corruption **maximal** entre 1998 et 2015

de l'ensemble des pays d'europe

Parlons un peu d’indexation

- **Indexer les lignes permet de dispenser le moteur de parcourir l’ensemble des lignes**

  → gain de vitesse et de ressource énorme !!!!

Sur quoi indexer ?

Rule of thumb : il vaut mieux indexer sur les champs typiquement impliqués dans des clauses de type **:**

- **WHERE**
- **ORDER BY**
- **GROUP BY**
- **MIN MAX** (dans le cas de valeurs numériques)

Il n’y a donc de bonnes et de mauvaise indexation que **relativement** i) aux requêtes adressées à la BDD ii) dans le **contexte d’un usage** de celle-ci

Comment indexer ?

En arbre équilibré

- Ou B-tree (balanced)
- InnoDB
- MyISAM

Par table de Hashage

NB : ces deux méthodes ne sont pas nécessairement exclusives (pensez à HEAP ou NDB cluster)

Par table de Hashage

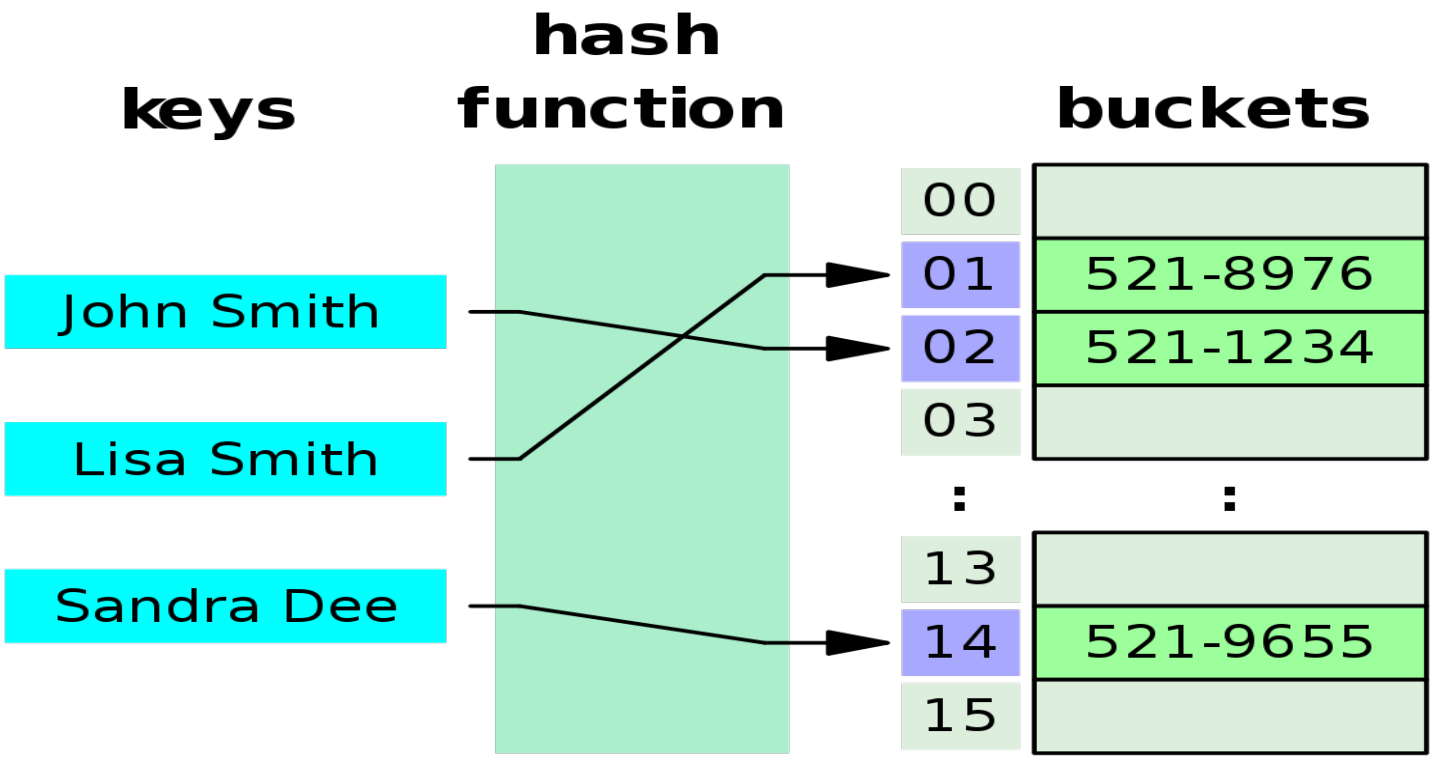

Deux types d’indexation en arbre à distinguer

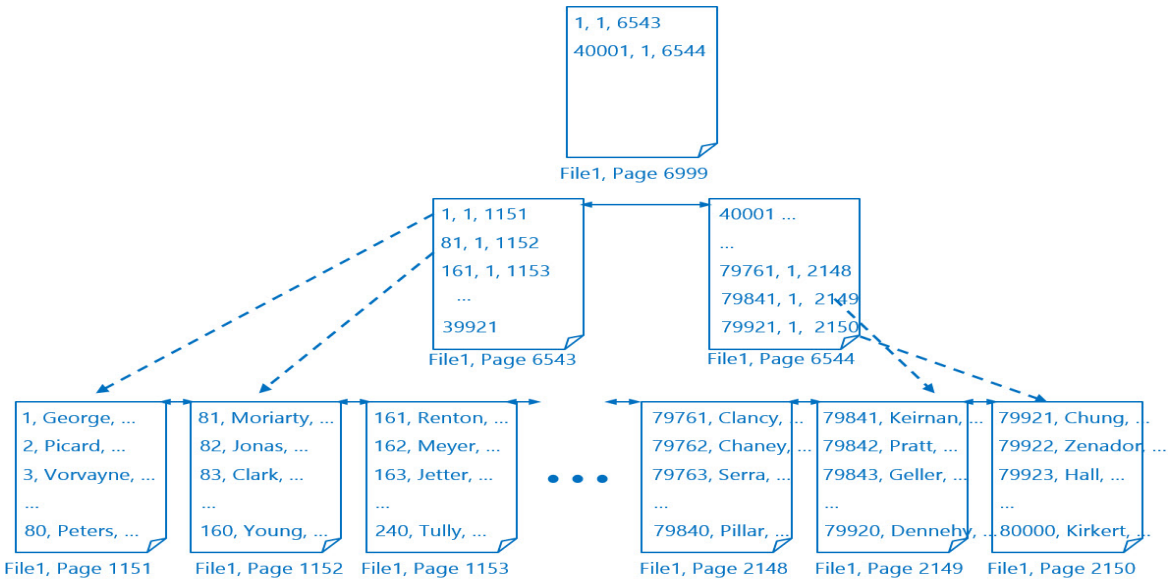

Clustered indexes

- Semblable à une recherche dans l’annuaire
- Solidaire de la BDD
- 1 seul possible arbre possible (car dépendant de l’ordre des données)

Deux types d’indexation en arbre à distinguer

Non Clustered indexes

- Système de pointers (identifiant les lignes)
- Distinct de la DBB
- Plusieurs indexes possibles

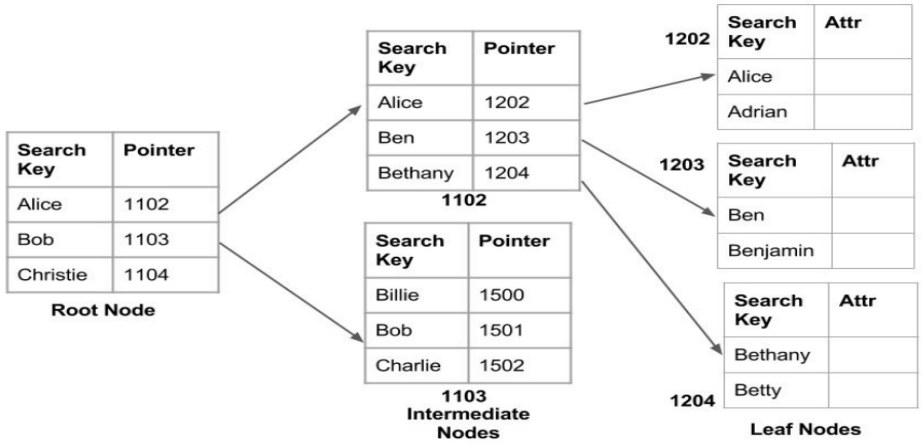

Non clustered index

Lister des indexes existants

```
SELECT
    tablename,
    indexname,
    indexdef
FROM
    pg_indexes
WHERE
    schemaname = 'public'
ORDER BY
    tablename,
    indexname;
```

Vous remarquerez que des indexes ont été créés automatiquement par l'action :

- primary keys
- foreign keys

La fonction EXPLAIN

Pour nous assurer du bon fonctionnement des indexations, nous allons avoir besoin d’un moyen de comparer de les requêtes avant et après indexation

```
EXPLAIN ANALYZE SELECT * FROM
mpi_subnational WHERE world_region_name =
‘Sub-Saharan Africa’;
```

Let’s explain EXPLAIN

Seq Scan on mpi_subnational (**cost**=0.00..24.30 **rows**=431 **width**=60)

Cost

rows

with

Creation d’un index

```
CREATE INDEX nom_index ON nom_table
(colonne_a_indexer);
```

Convention :

le nom des index contient « idx »

Nota Bene :

- Par défaut, Postgres crée des index de type B-Three
- En cas de valeur unique, a des fins d’optimisation, vous pouvez ajouter **UNIQUE**

Indexons nos tables rationnellement

Notez au passage :

- **Nous venons de réaliser une indexation de type « FULL TEXT »**
- **Seuls InnoDB et MyISAM permettent ce type d'indexation**
- **Restreint au colonnes de données de type CHAR, VARCHAR, TEXT**

Indexons nos tables rationnellement

Commençons par MPI_subnational. Créez un index pour world_region_name

```
CREATE INDEX idx_world ON
mpi_subnational(world_region_name);
```

Comparez **EXPLAIN**. Qu’en deduisez-vous ?

Indexons nos tables rationnellement

N’est-ce pas un peu c**, ce que nous venons de faire ?!
Comparons deux cas de figure

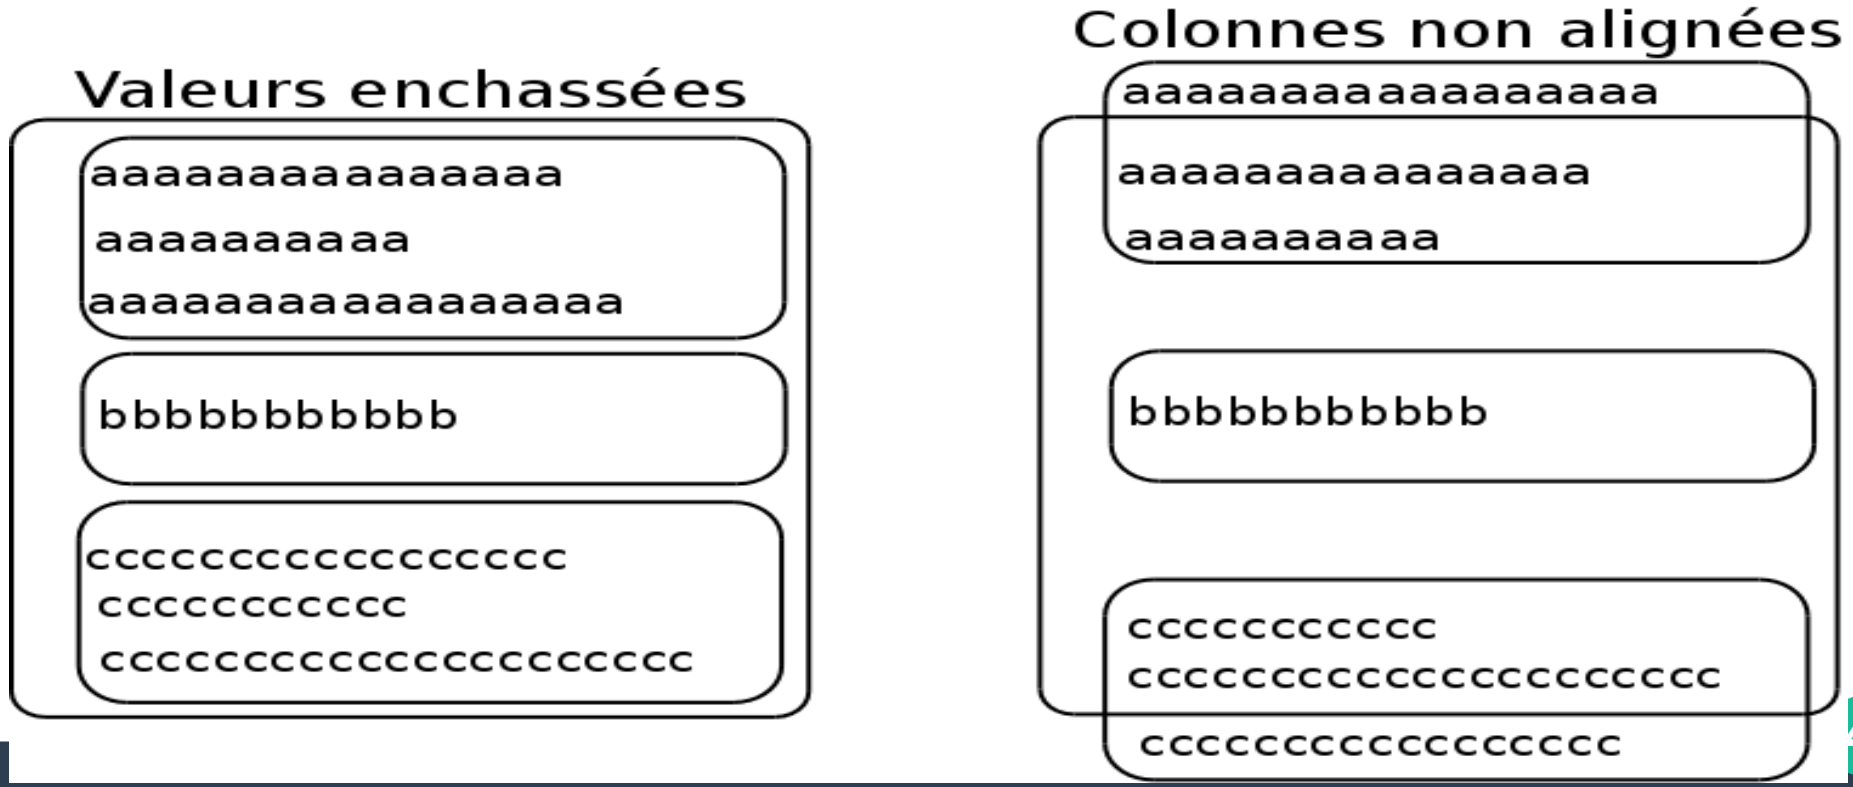

Indexons nos tables rationnellement

Dans le cas où les valeurs d’une des colonnes matchent toujours celle d’une autre colonnes, mieux vaut une **indexation multi-colonnes** que deux **index distincts**

- Point d’entrée unique
- Moins de charge en mémoire

Indexons nos tables rationnellement

Et passons à notre index multi-colonnes

```
CREATE INDEX idx_world_country ON MPI_subnational
(world_region,country_code);
```

NB :

- Règle du left most prefix
- Ne s’applique qu’à des indexes de type B-tree

Quelques down sides à garder à l’esprit

N’abusez pas des index car :

- Ils prennent de la place de mémoire
- Ils doivent être mis à jour à chaque requêtes d’insertion, modification, suppression

Solution rationnelle : distinguez, selon les besoins

- Des tables « stables » fortement indexées (requêtes de recherche)
- Des tables « volatiles » pas ou peu indexées

Trouvez des champs pertinents à indexer

Approches

- Pensez aux requêtes typiques
- Un peu de bon sens
- Approche empirique

A vous : essayons sur une grosse BDD

- **Une BDD d’un million de lignes**
- **https://www.sample-videos.com/download-sample-sql.php**

- **-** importez cette BDD dans une nouvelle BDD (videos)
- **-** trouvez des requêtes réalistes et utiles nécessitant plusieurs secondes d’exécution par le biais de joins entre ces tables
- **-** indexez de manière à mitiger ces latences

Trigger et fonctions

- Triggers et fonctions sont un moyen commode d’assurer l’intégrité d’une base dont les valeurs de certaines tables **dépendent de celles d’autres**

Situations typiques :

- Une table agrégée que l’on doit mettre à jour en cas de changement sur une autre
- Une table « *historique des changements* »

Anatomie d’un trigger réalisé avec plpgsql

La fonction

```
CREATE FUNCTION une_fonction() RETURNS
trigger AS $$
BEGIN
  IF TG_OP = 'INSERT' THEN
     ce_que_vous_voulez ;
  ELSIF TG_OP = 'DELETE' THEN
     ce_que_vous_voulez ;
  END IF;
  RETURN NEW;
END $$ LANGUAGE plpgsql;
```

Le trigger

```
CREATE TRIGGER
trigger1 AFTER
INSERT OR DELETE
on doc_tag

FOR EACH ROW

EXECUTE
PROCEDURE
une_fonction();
```

A nous

Création d’une table agrégée **par continent :**

- Le nombre de pays
- Taux de pauvreté urbain moyen
- Taux de pauvreté rural moyen

Création d’un trigger à même d’actualiser cette table en cas de

- **UPDATE**
- **INSERT**
- **DELETE**

Sauvegarde d’une BDD

En ligne de commande

pg_dump -U nom d’utilisateur nom_bdd > nom_bdd.pgsql

Graphiquement

PgAdmin

Importation d’une BDD à partir d’un pgsql

En ligne de commande

- créez une BDD
- **psql** -U nom d’utilisateur nom_bdd < nom_bdd.pgsql

Importation d’une BDD à partir d’un pgsql

Essayons d’importer cette base

- **http://www.postgresqltutorial.com/wp-content/uploads/2019/05/dvdrental.zip**

Parlons un peu de sécurité des BDD

Principe généraux d’une injection SQL

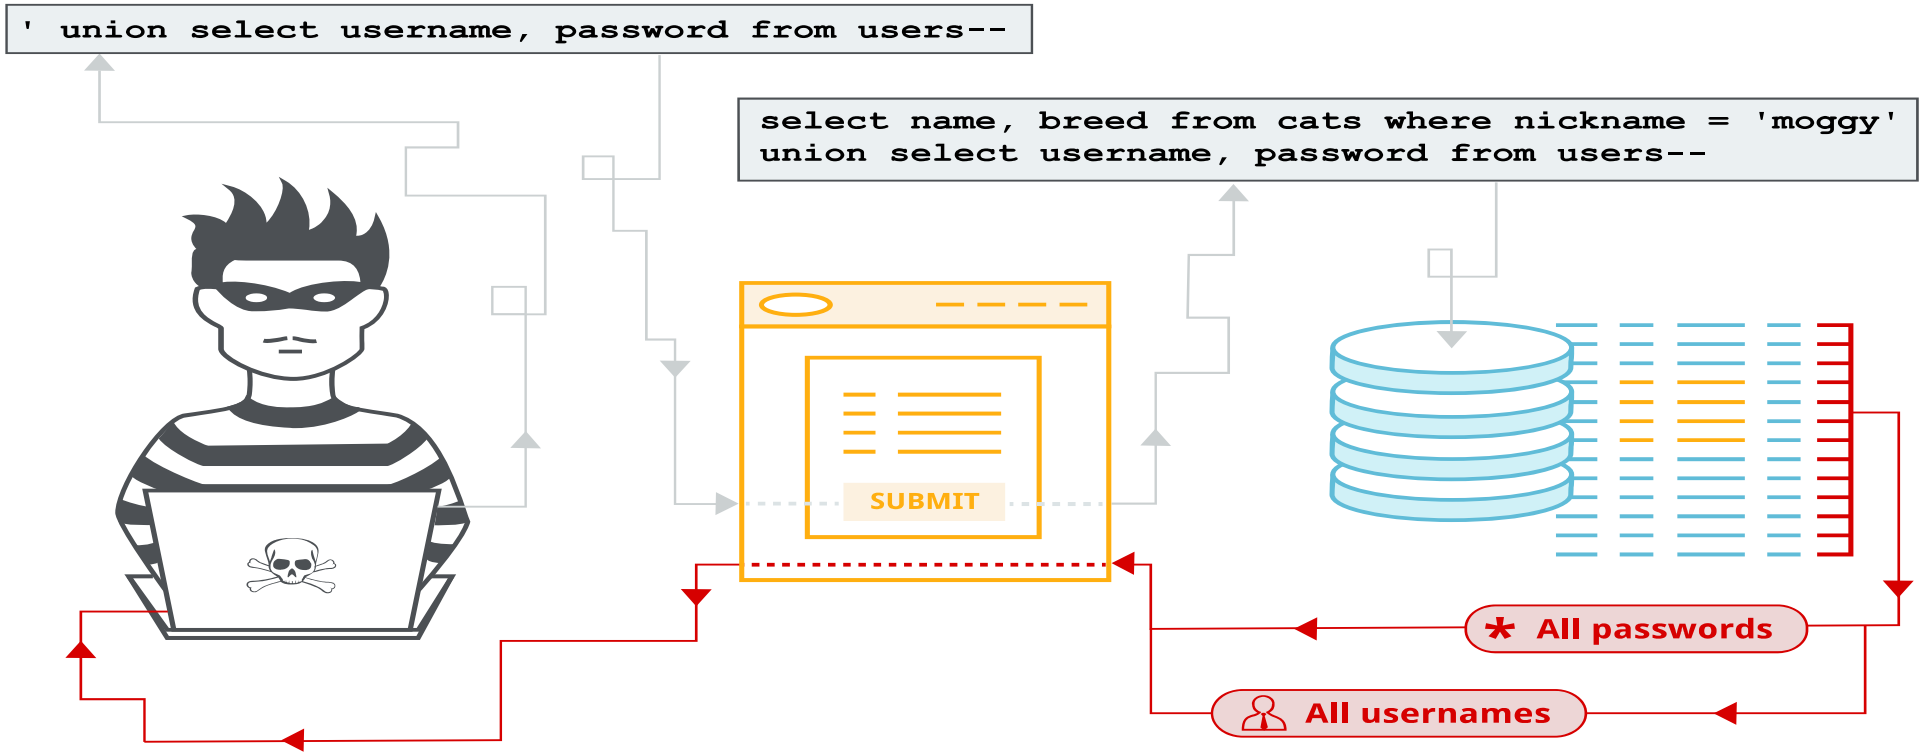

Principe généraux d’une injection SQL

Mettons que vous ayez le code (PHP) suivant derrière un formulaire d’authentification

```
txtUserId = getRequestString("UserId");
txtSQL = "SELECT * FROM Users WHERE UserId = " + txtUserId;
```

Entrer ceci dans le formulaire….

105 OR 1=1 →

…. donne la requête sql suivante:

```
SELECT * FROM Users WHERE UserId = 105 OR 1=1;
```

Principe généraux d’une injection SQL

Or, cette expression est toujours vraie.

Dans un langage déclaratif comme sql, cela implique que cette requête sera toujours exécutée (un parallèle avec un paradoxe logique)

Cette faille est ce que l’on appelle une disjonction (OR) avec une tautologie.

→ notez qu’il existe plein d’autres manières d’injecter

Ressources additionnelles

Challenges

- https://www.hackerrank.com/domains/sql